Ricerca predittiva regolata

Un esperimento sul giro di consegne

Francesco Vampa, Matricola 316461

31 ottobre 2026

Introduzione

Un corriere deve partire dal deposito, visitare tutte le consegne una volta e tornare al punto di partenza, percorrendo la minore distanza possibile. Questo è il problema del commesso viaggiatore, o TSP. Nel progetto i luoghi sono punti su un piano e le distanze sono misurate in linea retta, in unità arbitrarie: non rappresentano tempi di percorrenza su strade reali.

La domanda studiata è: *una previsione appresa può aiutare a scegliere quali percorsi approfondire, quando il tempo per cercare è limitato?* Confronto tre modalità di ricerca:

- **A, ricerca di base:** esplora i percorsi e scarta quelli già troppo costosi per migliorare il giro migliore trovato.
- **B, ricerca predittiva:** usa un modello allenato in precedenza per esplorare prima le continuazioni che sembrano meno costose.
- **C, ricerca predittiva regolata:** aggiunge un regolatore che cambia il prossimo candidato quando la ricerca non migliora da molti passi.

I casi di studio sono:

- **Dieci mappe da cento consegne:** confronto principale dei tre metodi, con uno e tre secondi disponibili per ogni ricerca.
- **Una mappa da sei consegne:** caso piccolo in cui è possibile verificare il giro ottimo e osservare un errore nell'ordine delle previsioni.
- **Una mappa personale da cento consegne:** prova esplorativa dell'effetto di sostituire il modello appreso.

Nella prova principale C riduce mediamente la distanza rispetto a B del 2,04% a un secondo e del 3,07% a tre secondi, ma peggiora alcune mappe. Le otto sezioni seguenti distinguono il contributo della previsione da quello della regolazione e discutono anche questi esiti sfavorevoli.

1 Ricerca

1.1 Come viene rappresentato il giro

La mappa contiene un deposito, indicato con 0, e n consegne numerate da 1 a n. Per confrontare due giri serve prima definire la distanza fra una coppia di luoghi. Se il luogo i ha coordinate (x_i, y_i) e il luogo j ha coordinate (x_j, y_j), la loro distanza in linea retta, indicata con $d(i, j)$, è

$$d(i,j) = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}.$$

Si può raggiungere direttamente ogni luogo da ogni altro: la mappa è quindi un grafo completo. Le distanze sono non negative e uguali nei due versi.

Un giro completo è una sequenza di luoghi. Lo indico con $r = (r_0, r_1, \ldots, r_n, r_{n+1})$: r_k è il luogo occupato nella posizione k del giro. Il primo e l'ultimo luogo sono il deposito, perciò $r_0 = r_{n+1} = 0$; nelle posizioni intermedie ogni consegna compare una sola volta.

La seguente formula calcola la distanza totale del giro, indicata con $J(r)$, includendo la partenza dal deposito e il ritorno dopo l'ultima consegna:

$$J(r) = \sum_{k=0}^{n} d(r_k, r_{k+1}).$$

L'obiettivo della ricerca è trovare l'ordine di visita che minimizza questo costo.

1.2 Che cosa rappresenta uno stato

Durante la ricerca il giro non è ancora completo. Devo conoscere il tratto percorso, le consegne ancora da visitare e la distanza già accumulata. Chiamo *stato* questa descrizione e la indico con $s = (p, N, g)$:

- p è la sequenza delle visite già decise, cioè il percorso parziale;
- N è l'insieme delle consegne rimaste;
- g è la distanza del percorso parziale, senza anticipare le tappe future.

Uso r per il giro completo e p per il suo tratto già costruito. Indico inoltre con v l'ultimo luogo di p, cioè la posizione corrente.

Espandere uno stato significa provare le possibili prossime visite. Se scelgo una consegna a ancora presente in N, ottengo un nuovo stato, chiamato s_a. La seguente formula descrive l'aggiornamento del percorso, delle consegne residue e del costo dopo la visita di a:

$$s_a = \big(p \parallel a,\ N \setminus \{a\},\ g + d(v, a)\big).$$

Ad esempio, dopo $p = (0, 2)$, in una mappa con tre consegne restano $N = \{1, 3\}$. Posso costruire il nuovo percorso $(0, 2, 1)$ oppure $(0, 2, 3)$. Ripeto il procedimento finché non ci sono più consegne da visitare: questo è uno *stato terminale*. A quel punto aggiungo la distanza per tornare al deposito e valuto il giro completo.

1.3 Ricerca di base e rami che si possono scartare

Il metodo A esplora in profondità: dopo aver scelto una continuazione, prova a completarla prima di tornare alle alternative rimaste. I candidati sono conservati in una pila, dalla quale si prende per primo l'ultimo inserito. I successori vengono inseriti per indice crescente. Questa strategia è una ricerca in profondità, detta anche DFS.

Per evitare lavoro inutile uso il *branch-and-bound*: confronto i percorsi parziali con il giro completo migliore già trovato. Chiamo J_{best} la distanza di quel giro. Prima di trovare un giro non ho ancora un limite utile e considero il valore infinito.

Se un percorso parziale è già lungo almeno quanto il giro migliore, completarlo non può produrre un miglioramento: le nuove distanze possono soltanto aumentare il costo. Posso quindi scartare tutto quel ramo quando

$$g \geq J_{\text{best}}.$$

Questo scarto è chiamato *potatura*. È sicuro perché usa distanze già percorse, non previsioni che potrebbero essere sbagliate. Per esempio, se ho trovato un giro di costo 100, un percorso parziale che costa già 110 non merita di essere completato.

La ricerca si ferma quando esaurisce i candidati oppure il tempo disponibile. Nel secondo caso restituisce il miglior giro trovato, senza dimostrare che sia ottimo; se non ha ancora completato un giro, non restituisce una soluzione. Se tutti i candidati sono stati valutati o potati correttamente, il giro migliore è invece ottimo. Sulle mappe grandi arrivare a questa conclusione richiederebbe un'esplorazione impraticabile.

1.4 Orizzonte e frontiera attiva

L'*orizzonte* è il confine dell'albero di ricerca costruito fino a un certo momento. Comprende i giri completi già valutati, i rami potati e i percorsi ancora in attesa. Non indica la profondità massima raggiunta.

La *frontiera attiva* è la parte di quel confine che può ancora ricevere calcolo: contiene i percorsi pendenti con costo $g < J_{\text{best}}$. I giri valutati e i rami già esclusi fanno parte dell'orizzonte, ma non sono candidati attivi. I contatori distinguono anche le potature effettuate prima di inserire un candidato da quelle effettuate quando viene estratto.

Alla scadenza del tempo i candidati attivi restano irrisolti. Un ramo potato è invece chiuso per una ragione precisa: non può migliorare la soluzione corrente. Questo riprende la distinzione delle lezioni fra ricerca *costruttiva*, che genera percorsi, e chiusura *complementare*, che giustifica dove non occorre proseguire.

2 Introduzione della previsione

2.1 Che cosa deve imparare il modello

Prima di usare il modello su una nuova mappa, lo alleno su esempi di percorsi parziali. Questa preparazione è detta fase *offline*. La fase successiva, in cui uso il modello già allenato per cercare un giro su una mappa, è detta *ricerca online*. Qui "online" indica la fase di utilizzo del modello, non una connessione a Internet.

Il modello deve prevedere quanta strada manca per visitare le consegne residue e tornare al deposito. Chiamo questa previsione $\widehat{h}(s)$. La distanza g già percorsa è nota e viene tenuta separata. Il valore ideale sarebbe il costo residuo ottimo, indicato con $h^*(s)$. Sulle mappe grandi, però, gli esempi di allenamento usano completamenti approssimati: la previsione cerca di riprodurre quei costi di riferimento.

2.2 Le informazioni usate per prevedere

Per descrivere ogni stato al modello scelgo quattro numeri, chiamati *feature*. Riassumono quanto resta da fare e la geometria delle prossime visite. Come nella Sezione 1, v è il luogo corrente e N l'insieme delle consegne residue. Chiamo m il loro numero, scritto anche $m = |N|$.

Simbolo	Informazione	Calcolo
x_1	Numero di consegne residue	m
x_2	Distanza dal luogo corrente al deposito	$d(v, 0)$
x_3	Distanza dalla consegna residua più vicina	$\min_{a \in N} d(v, a)$
x_4	Media delle distanze dalle consegne residue	$\frac{1}{m} \sum_{a \in N} d(v, a)$

Se non restano consegne, minimo e media sono posti a zero.

Durante la ricerca, quando tutte le consegne sono state visitate, **non serve prevedere la strada mancante**: l'unica tappa è il ritorno al deposito, e la sua distanza si legge direttamente dalla mappa.

2.3 Come viene calcolata la previsione

Uso una regressione lineare: il modello moltiplica ciascuna feature per un peso e somma i quattro contributi a un termine costante. Indico con $w_1, \dots, w_4$ i pesi e con b il termine costante, detto intercetta. La previsione è quindi

$$\widehat{h}(s) = b + \sum_{j=1}^{4} w_j x_j(s).$$

Nell'allenamento conosco, per ogni esempio, un costo rimanente di riferimento, chiamato *target* e indicato con $y(s)$. I pesi sono scelti per rendere piccole le differenze fra target e previsioni. Chiamando D_{train} l'insieme degli esempi di allenamento, il criterio è

$$\min_{b,w} \sum_{s \in D_{train}} \big(\widehat{h}(s) - y(s)\big)^2.$$

Questo criterio determina i pesi e l'intercetta minimizzando l'errore quadratico sui dati di allenamento. Le feature vengono usate nelle loro unità originali, senza normalizzarle.

2.4 Parametri appresi e limiti

Per il modello da cento consegne, l'intercetta e i quattro pesi risultano, arrotondati per la lettura:

$$b = 163{,}645698,$$
$$(w_1, w_2, w_3, w_4) = (6{,}027693;\ 0{,}017960;\ -1{,}597434;\ 1{,}667937).$$

Il peso negativo di x_3 è il risultato dell'allenamento con informazioni fra loro correlate. Non significa che allontanare una consegna renda necessariamente più breve il giro.

Queste quattro informazioni non descrivono tutta la disposizione dei punti: stati diversi possono avere le stesse feature e costi residui differenti. Anche il termine costante può pesare molto quando restano poche consegne. Il modello può quindi sovrastimare o sottostimare il costo rimanente: la sua previsione aiuta a scegliere l'ordine di esplorazione, ma non viene usata per scartare definitivamente un ramo.

3 Origine dei target

3.1 Come ottengo gli esempi di allenamento

Per allenare il modello non bastano le mappe: a ogni percorso parziale devo associare un esempio di quanto potrebbe costare finirlo. Questo valore di riferimento è chiamato *target*.

Lo ottengo con una ricerca svolta durante la preparazione dei dati, prima delle prove finali. Tale procedimento viene chiamato *insegnante* perché fornisce gli esempi da cui il modello impara. Mantiene fisso il percorso già deciso e completa soltanto le visite mancanti.

Chiamo $J_{teacher}(s)$ il costo del giro completo prodotto dall'insegnante partendo dallo stato s. Per ottenere la sola distanza rimanente sottraggo il costo già percorso, $g(s)$. Il target, indicato con $y(s)$, è quindi

$$y(s) = J_{teacher}(s) - g(s).$$

3.2 Mappe piccole e mappe grandi

Sulle mappe da sei consegne posso cercare tutte le alternative necessarie a certificare il giro migliore. Uso branch-and-bound, con un limite di 100 000 estrazioni, e conservo l'esempio soltanto se la ricerca termina con un ottimo dimostrato. Il dataset piccolo contiene dieci mappe: otto forniscono 15 648 stati per allenare il modello e due forniscono 3 912 stati per verificarlo. Queste ultime sono state usate anche nelle prove preliminari sul regolatore e non costituiscono una verifica finale indipendente. Il caso piccolo della Sezione 8 usa un'ulteriore mappa, estranea a questo dataset, individuata nelle prove precedenti.

Su cento consegne cercare l'ottimo richiederebbe troppo lavoro. Uso quindi un insegnante approssimato. Provo tre possibili prime visite, scelte fra le consegne più vicine alla posizione corrente. Per ciascuna completo il giro scegliendo ogni volta la consegna più vicina fra quelle rimaste: questa regola è chiamata *nearest-neighbor*.

Miglioro poi il giro con la tecnica *2-opt*: inverto tratti della sequenza quando questo accorcia la distanza, senza modificare le visite già fissate nel percorso iniziale. Eseguo fino a sei passate e conservo il completamento meno costoso fra quelli provati.

Il giro ottenuto rispetta il vincolo di visitare tutte le consegne, ma non è necessariamente ottimo. Il suo costo residuo può quindi essere maggiore del minimo possibile. Il modello impara ad approssimare questo riferimento e può, a sua volta, stimare un valore più alto o più basso.

3.3 Quali mappe uso per allenare e verificare

Il dataset grande contiene quindici mappe con cento consegne ciascuna: dodici per l'allenamento e tre per verificare le previsioni. Il deposito è nell'origine; le coordinate di ogni consegna sono scelte uniformemente fra 0 e 100 su entrambi gli assi. Questa regione si indica con $[0, 100]^2$.

Per ogni mappa seleziono quaranta stati distribuiti fra l'inizio del giro e il momento in cui resta una sola consegna. Alterno percorsi parziali ricavati da un ordinamento casuale e da un giro nearest-neighbor. Gli stati della stessa mappa condividono quindi la disposizione dei punti e derivano da due ordinamenti: non sono osservazioni indipendenti.

Ottengo 480 esempi di allenamento e 120 di verifica. Tengo separate le mappe, anziché distribuire casualmente i loro stati nei due gruppi, per verificare il modello su disposizioni che non ha già visto. Le dieci mappe del confronto finale sono ulteriori e non appartengono a nessuno dei due gruppi.

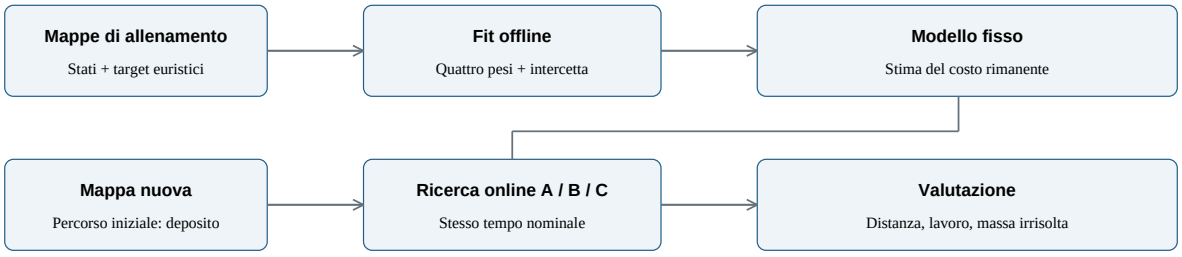


Figura 1: Le mappe di allenamento e i target servono a preparare il modello. Nella successiva fase di ricerca lo stesso modello viene usato su mappe nuove. I riferimenti di valutazione non vengono forniti come giri iniziali.

Per valutare le soluzioni delle mappe grandi calcolo inoltre un riferimento più impegnativo: dodici prime visite e fino a venti passate di 2-opt. Anche questo giro è approssimato e non certifica l'ottimo. Allenamento, costruzione dei target e riferimenti vengono svolti separatamente dal tempo assegnato ai tre metodi nelle prove finali.

4 Ricerca predittiva

Il metodo B usa il modello per scegliere quali continuazioni esplorare prima. Per confrontarle deve considerare sia la distanza già percorsa, $g(s)$, sia quella ancora prevista, $\widehat{h}(s)$. Chiamo $\widehat{f}(s)$ la loro somma, cioè la stima della distanza totale del giro che passa da quello stato:

$$\widehat{f}(s) = g(s) + \widehat{h}(s).$$

Ad esempio, uno stato con $g = 100$ e $\widehat{h} = 80$ ha costo totale previsto 180. Uno con $g = 140$ e $\widehat{h} = 50$ ha costo totale previsto 190. Il primo viene preferito, anche se il secondo ha una previsione residua minore.

Dopo ogni espansione, B ordina i nuovi candidati secondo questa stima, in modo da proseguire prima lungo il meno costoso. Il confronto avviene fra i successori dello stesso stato: non viene riordinata tutta la frontiera. La ricerca conserva quindi il comportamento in profondità descritto per A.

Questa precisazione distingue B da A*: pur usando anch'esso una somma di costo percorso e costo previsto, A* sceglie il prossimo stato confrontando globalmente i candidati della frontiera. Nel progetto l'ordinamento è locale.

A e B usano la stessa regola di potatura; cambia l'ordine di esplorazione. Il confronto A–B misura dunque il contributo della previsione. C aggiunge la regola di scelta descritta nella sezione seguente, quindi B–C permette di misurare il contributo aggiuntivo del regolatore.

Una previsione sbagliata può far esplorare tardi un buon ramo e peggiorare il giro trovato entro il tempo disponibile. Non rende però scorretta la potatura, che continua a usare soltanto la distanza già percorsa. Se la ricerca riesce a esaminare o escludere correttamente tutte le alternative, trova comunque l'ottimo. I pesi del modello restano fissi per tutta la ricerca.

5 Regolazione della ricerca predittiva

5.1 Quando cambiare candidato

Il metodo C usa le stesse previsioni e potature di B. Il regolatore osserva se la ricerca continua senza migliorare il giro e, in quel caso, prova a cambiare il prossimo candidato da approfondire. Un cambiamento di questo tipo viene chiamato *diversificazione*.

Per decidere quando intervenire uso due contatori:

- q: quanti stati sono stati estratti dall'ultimo miglioramento della distanza del giro migliore;
- c: quante estrazioni ordinarie sono avvenute dall'ultima diversificazione, per lasciare tempo alla ricerca predittiva fra due interventi.

Entrambi partono da zero. Fisso una soglia, indicata con P, uguale a 100. Il regolatore interviene soltanto quando *entrambi* i contatori hanno raggiunto la soglia:

$$q \geq P \quad \text{e} \quad c \geq P.$$

Quando la condizione è soddisfatta, invece di prendere l'ultimo candidato inserito nella pila scelgo quello con la distanza già percorsa g minore. In caso di parità scelgo il primo presente nella pila. Le altre alternative restano disponibili. Se la condizione non è soddisfatta, la scelta rimane quella ordinaria di B.

La corrispondenza con la consegna è quindi: le *osservazioni* sono i due contatori; la *regola* verifica le soglie; il *controllo* cambia quale candidato riceve il prossimo passo di ricerca.

5.2 Come cambiano i contatori

Ogni estrazione aumenta q, anche se il candidato è un giro completo o viene subito scartato. Trovare un giro strettamente più corto del migliore lo azzera. Prima del primo giro, q conta le estrazioni dall'avvio.

Un'estrazione ordinaria aumenta c. Una diversificazione lo azzera, così devono trascorrere almeno altre cento estrazioni ordinarie prima di un nuovo intervento. La condizione viene controllata prima di estrarre: se dall'avvio non ci sono miglioramenti, il primo intervento può quindi avvenire al passo 101.

5.3 Motivazione e limiti

L'assenza prolungata di miglioramenti è chiamata *stagnazione*. È un segnale semplice: suggerisce di provare un candidato diverso, ma non dimostra che il modello stia sbagliando. Anche scegliere il costo parziale minore può essere poco utile, perché un percorso appena iniziato ha spesso una distanza bassa pur lasciando molto lavoro da fare. Il nuovo candidato può inoltre appartenere allo stesso primo ramo.

Per trovare il minimo devo esaminare tutti i candidati nella pila. Se sono molti, questo intervento richiede tempo; espandere percorsi poco profondi può anche aggiungere molti nuovi candidati. Le prove misurano quindi sia la qualità dei giri sia il lavoro svolto.

La regola e la soglia restano fisse durante le prove. Non ho cercato sistematicamente la soglia migliore sulle mappe finali e non alleno il regolatore durante la ricerca. Il confronto B–C serve proprio a verificare quando questa scelta semplice aiuta e quando peggiora il risultato.

6 Errore di previsione e bisogno di ricerca

6.1 Come misuro l'errore

Per capire se il modello ha imparato qualcosa di utile confronto le sue previsioni con i target delle mappe escluse dall'allenamento. Per ogni stato considero la differenza, in valore assoluto, fra costo di riferimento e costo previsto; poi faccio la media di queste differenze. Questa misura è l'*errore assoluto medio*, abbreviato MAE.

Indico con M il numero di esempi di verifica, con s_i lo stato del i-esimo esempio, con y_i il suo target e con $\widehat{h}(s_i)$ la previsione. La formula è

$$\mathrm{MAE} = \frac{1}{M} \sum_{i=1}^{M} \left| y_i - \widehat{h}(s_i) \right| .$$

Un MAE minore indica previsioni mediamente più vicine ai target.

Per avere un confronto semplice considero anche un predittore che risponde sempre con lo stesso numero: la media dei target di allenamento, pari a 538,135. Non è il metodo A: A cerca un percorso, mentre questa previsione costante serve soltanto a valutare il modello.

Sui 120 stati di verifica il modello ha MAE 49,391, contro 184,684 della costante: l'errore medio si riduce di circa il 73,26%. Come controllo aggiuntivo, considero anche la radice della media degli errori al quadrato, detta RMSE, che dà più peso agli errori grandi: risulta 60,214. Infine calcolo il *bias*, cioè la media delle differenze con segno fra previsione e target: è 0,175. Un bias vicino a zero non implica che le singole previsioni siano corrette: le sovrastime possono compensare le sottostime.

L'accuratezza cambia con il numero di consegne rimaste. Negli intervalli 1–25, 26–50, 51–75 e 76–100, i MAE sono rispettivamente 54,632, 66,334, 47,150 e 29,448. Anche fra le tre mappe l'errore

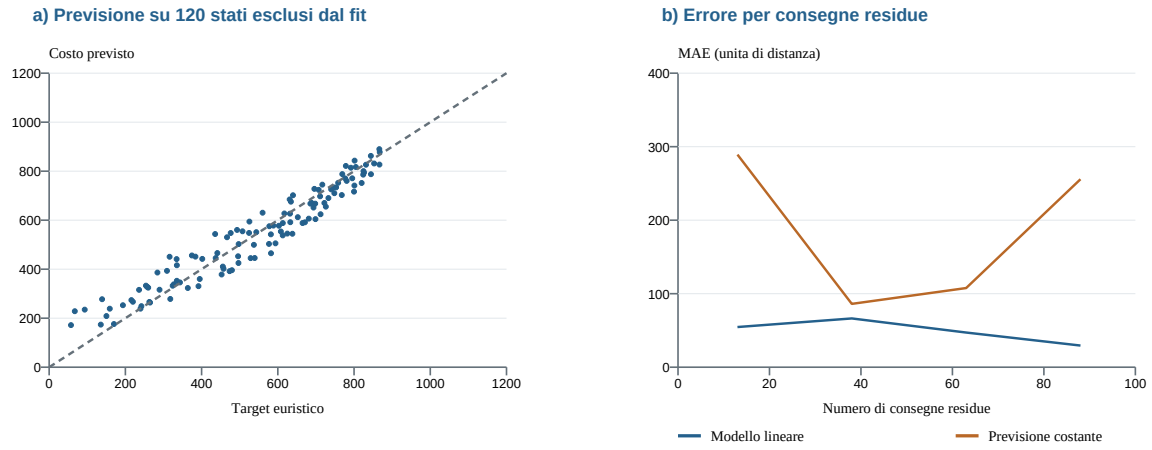


Figura 2: A sinistra ogni punto confronta il target di uno stato con la previsione: sulla diagonale i due valori coincidono. A destra confronto l'errore medio del modello e della previsione costante in quattro intervalli di consegne residue, ciascuno con 30 stati. Gli stati provengono da sole tre mappe e non sono osservazioni indipendenti.

medio varia: 37,237, 51,159 e 59,777. La sola media globale nasconderebbe queste differenze. Poiché i target grandi sono approssimati, questi valori misurano la distanza dall'insegnante, non l'errore esatto rispetto al giro ottimo.

6.2 Errore e utilità di continuare a cercare

Posso anche chiedermi di quanto una singola previsione cambi dopo aver approfondito la ricerca. Chiamo questa differenza *residuo*. Indico con $h_{\text{rif}}(s)$ il costo rimanente ottenuto dal riferimento e con $r(s)$ il residuo:

$$r(s) = h_{\text{rif}}(s) - \widehat{h}(s).$$

Un residuo positivo significa che il modello prevedeva un costo troppo basso; uno negativo significa che lo prevedeva troppo alto, rispetto al riferimento. La stessa differenza si ottiene confrontando costi totali, perché la distanza già percorsa è uguale nei due valori e si cancella.

Conoscere il residuo richiede la ricerca aggiuntiva del riferimento: non è un'informazione disponibile in anticipo al regolatore. Inoltre, un ramo con un grande errore di previsione può comunque portare a un giro peggiore degli altri. L'entità dell'errore e il beneficio di esplorare quel ramo sono quindi due quantità diverse. Il caso piccolo della Sezione 8 rende concreta questa distinzione.

Non alleno un secondo modello per prevedere l'errore. Il regolatore usa la stagnazione come segnale per cambiare candidato e le prove verificano se questa scelta migliora i giri trovati. Non dimostro una relazione statistica fra stagnazione, residuo e miglioramento futuro: è un limite della proposta.

7 Scelta probabilistica e massa irrisolta

7.1 Come assegno un peso alle prime scelte

Considero un momento preciso: la scelta della prossima consegna a partire dallo stato iniziale della prova, chiamato s_0. In genere il percorso iniziale contiene soltanto il deposito. Scegliere una prima consegna significa aprire il ramo di tutti i giri che iniziano con quella visita.

Voglio assegnare più peso ai rami con costo previsto minore. Per farlo trasformo le stime dei costi in numeri positivi la cui somma è uno, cioè in una distribuzione di probabilità. La trasformazione usata è chiamata *softmax*. Prima della formula, i simboli necessari sono:

- a: una possibile prossima consegna; s_a è lo stato che ottengo visitandola, come definito nella Sezione 1;
- $\widehat{f}(s_a)$: la distanza totale prevista passando da quello stato;
- $f_{\min}$: il più piccolo costo previsto fra tutte le prime scelte;
- T: un parametro positivo, chiamato *temperatura*, che controlla quanto i pesi sono concentrati sulle scelte preferite;
- $\pi(a \mid s_0)$: il peso assegnato alla scelta a, partendo da s_0.

La formula seguente assegna a ogni prima scelta una probabilità ricavata dal costo previsto; u rappresenta le alternative disponibili:

$$\pi(a \mid s_0) = \frac{\exp[-(\widehat{f}(s_a) - f_{\min})/T]}{\sum_u \exp[-(\widehat{f}(s_u) - f_{\min})/T]}.$$

Costi previsti minori ricevono probabilità maggiori. Sottrarre il minimo migliora la stabilità numerica senza modificare la distribuzione.

Uso come temperatura la distanza media fra tutte le coppie di luoghi; se tutte le distanze sono nulle, pongo $T = 1$. Una temperatura alta rende i pesi più simili, una bassa li concentra sulle stime migliori. Questi pesi esprimono preferenze del modello, non la probabilità dimostrata che un ramo contenga il giro ottimo.

La ricerca non sceglie azioni a sorte: B e C continuano a usare le proprie regole deterministiche. La distribuzione resta fissa dall'avvio e serve per descrivere i rami ancora irrisolti. A non la usa per scegliere i candidati e il regolatore di C osserva soltanto i due contatori. Cambiare la temperatura modifica dunque i pesi osservati, ma non l'ordine di ricerca del sistema realizzato. Se non ci sono consegne residue, non ci sono prime scelte a cui assegnare probabilità.

7.2 Quale parte della preferenza rimane irrisolta

Durante la ricerca alcuni rami possono essere chiusi, mentre altri conservano candidati da esaminare. Per descrivere il peso di questi ultimi uso la *massa irrisolta*: sommo le probabilità delle prime scelte che hanno ancora almeno un candidato attivo nel proprio ramo.

Chiamo t il passo corrente della ricerca, U_t l'insieme di queste prime scelte ancora irrisolte e ρ_t la loro massa complessiva. La formula è

$$\rho_t = \sum_{a \in U_t} \pi(a \mid s_0).$$

Ogni prima scelta viene contata una sola volta, anche se nel suo ramo restano molti candidati. Per esempio, se tre scelte hanno pesi 0,6, 0,3 e 0,1 e il primo ramo è stato risolto interamente, la massa delle altre due è 0,4.

Trovare un buon giro nel primo ramo non basta a risolverlo: se contiene altre continuazioni attive, anche il suo peso resta nella somma. Prima di espandere lo stato iniziale tutte le scelte sono irrisolte e la massa vale uno; quando la frontiera è esaurita vale zero.

Questa misura non indica quanti stati mancano da visitare né la probabilità di aver perso l'ottimo. Sulle mappe grandi resta circa uno, perché ogni prima scelta conserva almeno un candidato attivo ai tempi considerati. In questo esperimento distingue quindi poco i metodi e non viene usata per decidere quando fermare la ricerca.

8 Esperimento

8.1 Domanda sperimentale e protocollo

Confronto A, baseline DFS con branch-and-bound; B, stessa ricerca con ordine predittivo; C, stessa ricerca predittiva con regolatore. Le dieci mappe finali sono nuove rispetto al dataset iniziale; ciascuna ha cento consegne uniformi in $[0, 100]^2$ e deposito nell'origine. I tre metodi ricevono esattamente le stesse coordinate e ripartono dal deposito, senza giri iniziali. Il modello da cento consegne e la soglia del regolatore, $P = 100$, rimangono fissi.

Per ogni mappa assegno un budget nominale di uno e tre secondi per metodo. Ogni combinazione è ripetuta tre volte, con ordine dei metodi ruotato: ciascuno occupa una volta ogni posizione. Le ricerche sono sequenziali, non concorrenti. Un'esecuzione completa contiene $10 \cdot 2 \cdot 3 \cdot 3 = 180$ ricerche grandi, oltre al caso piccolo. Le prestazioni temporali dipendono dal computer e dalle altre attività in esecuzione durante la prova.

Il timer include ciclo di ricerca, previsioni, ordinamenti, scansioni e monitoraggio durante le estrazioni. Esclude costruzione della matrice, distribuzione iniziale dei pesi, riferimenti di valutazione e riepilogo finale. Distinguo il tempo impiegato a cercare, chiamato t_{search}, dal tempo comprensivo del riepilogo finale delle statistiche, chiamato t_{tot}. Il controllo della scadenza è fra iterazioni: non interrompe un'operazione in corso. Il confronto è quindi a risorse approssimativamente uguali, come richiesto dalla consegna, con sforamenti misurati e dichiarati.

La qualità viene misurata dalla distanza totale del miglior giro, incluso il ritorno. Per ogni mappa e metodo uso la mediana di tre ripetizioni; un fallimento nel trovare un giro non viene escluso silenziosamente dalla mediana. Nelle prove qui riportate tutti i metodi trovano un giro. Per distinguere i contributi considero due riduzioni percentuali. Chiamo J_A, J_B e J_C i costi mediani ottenuti dai tre metodi sulla stessa mappa e con lo stesso tempo assegnato. Il guadagno della previsione, G_{pred}, confronta B con A; quello della regolazione, G_{reg}, confronta C con B. Li calcolo così:

$$G_{pred} = 100\frac{J_A - J_B}{J_A}, \qquad G_{reg} = 100\frac{J_B - J_C}{J_B}.$$

Calcolo prima queste percentuali per mappa, poi ne faccio la media: non uso il rapporto fra i costi medi di mappe diverse. Un valore positivo indica una riduzione di distanza; un G_{reg} negativo indica invece che C peggiora B. Sulle mappe grandi non conosco l'ottimo e quindi non presento queste percentuali come gap dall'ottimo.

8.2 Risultati A/B/C a un secondo

La Tabella 1 mostra i costi mediani della seconda esecuzione completa, la stessa già analizzata nella versione iniziale della relazione. Il riferimento a dodici partenze è calcolato separatamente e non inizializza nessuna delle ricerche. È riportato per rendere visibile anche la qualità assoluta dei giri, oltre al confronto relativo fra A, B e C.

B migliora A in tutte le dieci mappe, con riduzione media del 75,20%. C migliora ulteriormente B su sei mappe e peggiora sulle altre quattro: il guadagno medio aggiuntivo è 2,04%. Il vantaggio non è uniforme: C perde circa 2,30% sulla mappa 1 e guadagna 10,37% sulla mappa 8. Differenze molto piccole, come sulla mappa 5, non vanno interpretate come prove forti di superiorità di un metodo.

8.3 Risultati A/B/C a tre secondi

Mantengo mappe, modello e soglia, aumentando il tempo nominale; ogni ricerca riparte da zero. La Tabella 2 riporta i risultati.

Tabella 1: Distanza totale a 1 secondo: mediana di tre ricerche. In grassetto il migliore fra A, B e C. Il riferimento è euristico, calcolato offline e non usato per inizializzare le ricerche.

Mappa	A: base	B: predittiva	C: regolata	Riferimento
1	5032,171	**1232,194**	1260,496	786,283
2	4550,280	1238,428	**1199,187**	796,045
3	4535,162	**1209,358**	1216,796	822,359
4	5184,191	1247,886	**1246,064**	867,593
5	4880,372	**1271,490**	1272,012	847,655
6	5051,347	1203,630	**1177,426**	841,372
7	4865,337	1243,174	**1149,282**	803,150
8	5232,949	1283,231	**1150,133**	806,291
9	5037,756	**1146,193**	1150,825	812,547
10	5293,862	1210,492	**1206,202**	851,533

Tabella 2: Distanza totale a 3 secondoi: mediana di tre ricerche. In grassetto il migliore fra A, B e C. Il riferimento è euristico, calcolato offline e non usato per inizializzare le ricerche.

Mappa	A: base	B: predittiva	C: regolata	Riferimento
1	4946,385	1229,267	**1183,694**	786,283
2	4542,940	1237,996	**1199,187**	796,045
3	4516,857	1207,742	**1160,431**	822,359
4	5142,859	**1242,330**	1245,519	867,593
5	4869,099	1271,490	**1257,145**	847,655
6	5039,634	1199,439	**1177,426**	841,372
7	4834,985	1240,967	**1149,282**	803,150
8	5231,129	1283,231	**1150,133**	806,291
9	4990,438	**1146,193**	1150,825	812,547
10	5281,628	**1204,769**	1206,202	851,533

B mantiene un vantaggio medio del 75,11% su A. C supera B in sette mappe, con guadagno medio del 3,07%. Sulle mappe 1 e 3 passa da un esito peggiore a uno migliore di B. Sulla mappa 9 resta peggiore e sulle mappe 4 e 10 diventa peggiore: un budget maggiore non garantisce un vantaggio relativo della regolazione in ogni caso. Se B continua a migliorare mentre C resta stabile, anche un giro di C invariato può perdere il confronto.

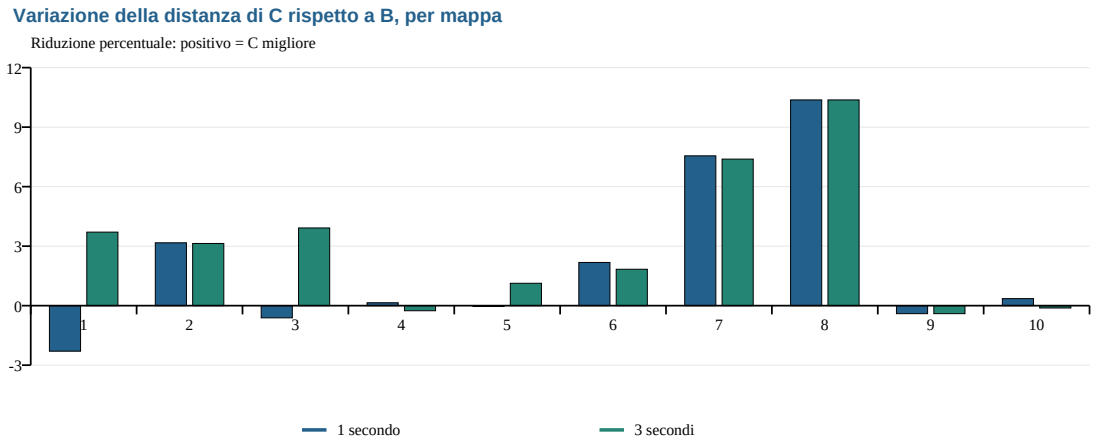


Figura 3: Contributo aggiuntivo della regolazione nelle dieci mappe, usando le mediane della seconda esecuzione. Le barre negative mantengono visibili i peggioramenti. Ogni coppia di barre riguarda la stessa mappa; non sono intervalli di confidenza.

Il riferimento euristico trova giri nettamente più corti di A, B e C. Il grande vantaggio B–A va quindi letto rispetto alla specifica DFS con limite inferiore debole scelta come baseline, non come superiorità rispetto alle migliori tecniche per il TSP. Il calcolo separato del riferimento non è a parità di budget con A/B/C e non attribuisco al riferimento un vantaggio temporale.

8.4 Quanto lavoro viene svolto

La Tabella 3 riporta mediane sulle trenta ricerche per metodo e budget della seconda esecuzione. Gli stati estratti includono terminali e potati; le valutazioni del modello contano quelle usate per ordinare i figli, non quelle usate per preparare i pesi iniziali prima della ricerca. Le scansioni contano gli elementi esaminati dal regolatore, non il numero dei suoi interventi.

Tabella 3: Mediane sulle 30 ricerche per metodo e budget della seconda esecuzione. Frontiera è il numero finale di candidati attivi, non il picco né una misura in byte. I conteggi sono arrotondati all'intero. Scansioni conta gli elementi esaminati nelle diversificazioni; t_{tot} include il riepilogo finale.

Budget	Metodo	Estratti	Frontiera	Previsioni	Scansioni	t_{tot} (s)
1	A	461032	4924	0	0	1,002
1	B	164090	4918	633560	0	1,002
1	C	3751	159578	163644	2679596	1,071
3	A	1253402	4918	0	0	3,002
3	B	449692	4917	1919652	0	3,002
3	C	8630	381600	391450	15639974	3,171

A un secondo, A estrae circa 461 000 stati, B 164 000 e C soltanto 3 751. C mantiene però circa 160 000 candidati attivi finali, contro circa 4 900 degli altri metodi, e scansiona circa 2,68 milioni di candidati. A tre secondi la sua frontiera finale mediana sale a circa 382 000, con 15,64 milioni di elementi scansionati. Il regolatore cambia quindi il costo per estrazione e l'ampiezza esplorata.

Questi dati sono compatibili con l'ipotesi che scansioni e preferenza per prefissi poco profondi ne limitino l'efficienza; non isolano causalmente l'origine dei singoli peggioramenti.

La massa irrisolta finale resta circa uno per tutti e tre i metodi: ogni prima scelta conserva almeno un candidato attivo. Non distingue bene le soluzioni ai budget considerati. La frontiera finale è solo un indicatore della struttura pendente: non ho misurato il picco di memoria o i byte usati.

8.5 Ripetizioni e stabilità

Sono disponibili tre esecuzioni complete: due del 30 ottobre e una del 31 ottobre, tutte sulle stesse mappe. Nelle prime due le mediane dei costi di B e C coincidono; per A cambia una sola mappa a tre secondi, di circa lo 0,52%. Nella terza cambiano leggermente alcune distanze, ma i conteggi di vittorie di C restano sei e sette. La Tabella 4 rende esplicita questa variabilità senza selezionare soltanto l'esecuzione favorevole.

Tabella 4: Ripetizioni dell'intero protocollo sulle stesse dieci mappe, in ordine cronologico. Le mappe indipendenti rimangono dieci; i guadagni usano le mediane interne a ciascuna esecuzione.

Esecuzione	Budget (s)	C migliore / 10	Guadagno C su B	Massimo t_C (s)
1	1	6	2,04%	1,093
1	3	7	3,07%	3,257
2	1	6	2,04%	1,117
2	3	7	3,07%	3,213
3	1	6	2,00%	1,098
3	3	7	3,08%	3,240

Il massimo osservato per il ciclo di C è circa 1,12 secondi a budget uno e 3,26 a budget tre nelle prime due esecuzioni; la tabella include anche la terza. Il riepilogo finale aggiunge ulteriore tempo, come mostra t_{tot} in Tabella 3. Non affermo quindi che C sia più veloce. Gli sforamenti possono contribuire alle differenze di qualità, soprattutto quando sono piccole: il confronto non isola perfettamente la diversa allocazione da eventuale tempo aggiuntivo. Le 540 ricerche grandi complessive non diventano 540 mappe indipendenti: i casi indipendenti rimangono dieci. Non uso queste ripetizioni come una prova di significatività statistica o di generalizzazione a mappe differenti.

8.6 Caso esatto: esplorare un ramo sfavorito è utile

Riproduco un caso illustrativo da sei consegne già individuato nelle prove precedenti, con un modello distinto allenato su mappe piccole. Non è un nuovo caso selezionato casualmente per confermare il risultato finale. L'enumerazione di tutte le permutazioni permette di conoscere il miglior completamento sotto ogni prima scelta. La Tabella 5 confronta previsioni, riferimenti e lavoro assegnato ai rami. In questa tabella $\widehat{f}$ è il costo totale previsto e f^* il miglior costo totale esatto del ramo, ottenuto provando tutti gli ordini di visita. Il rango indica la posizione del ramo nell'ordine delle previsioni: il rango 1 è la scelta preferita dal modello.

Tabella 5: Caso piccolo: previsioni alla prima scelta, completamenti esatti offline ed estrazioni allocate con budget 500. Il rango 1 indica la previsione preferita; il residuo è $f^* - \widehat{f}$.

Prima visita	Rango	$\widehat{f}$	f^*	Residuo	Estratti B	Estratti C
2	1	280,398	354,992	74,593	251	251
4	2	304,514	396,500	91,986	181	33
1	3	318,882	386,591	67,708	67	0
3	4	323,928	407,153	83,225	0	0
5	5	330,000	349,580	19,580	0	101
6	6	340,181	349,580	9,400	0	114

Il ramo che inizia dalla consegna 6 è ultimo per previsione, ma contiene un giro ottimo di costo 349,580. Entro 500 estrazioni B non lo visita e trova costo 354,992, cioè gap 1,548% dall'ottimo. C apre il ramo al passo 387 e trova l'ottimo al passo 421; A lo trova già al passo 239. C migliora quindi B in questo caso, ma non domina la baseline. La simmetria del giro euclideo spiega perché anche il ramo che inizia da 5 contenga un ottimo: i due versi dello stesso giro non sono prove indipendenti.

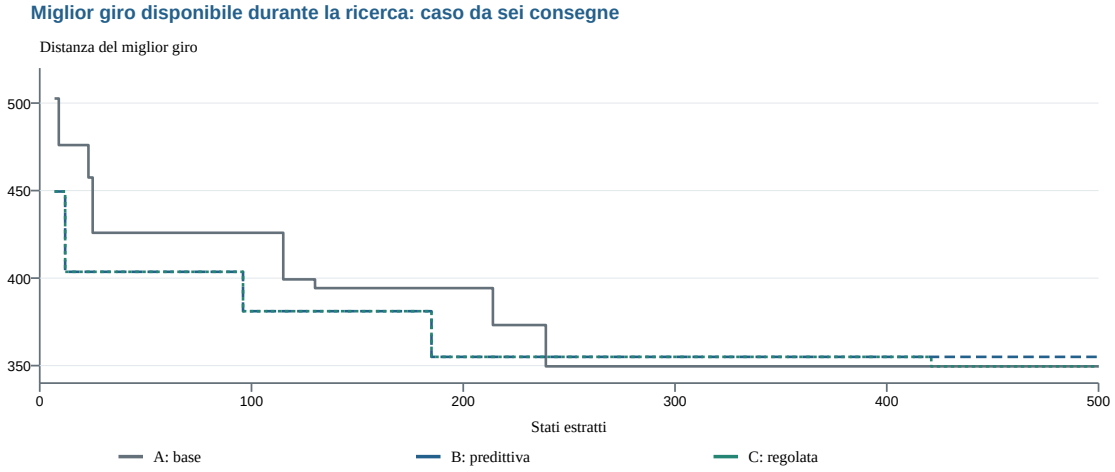


Figura 4: Traccia dei miglioramenti nel caso piccolo: asse orizzontale in estrazioni, non in secondi. Le curve iniziano dal primo giro trovato. B e C coincidono fino al passo 185; C migliora ancora al passo 421. Il confronto a parità di stati non implica parità di tempo.

Il residuo del ramo 6 è 9,400, mentre quello maggiore, 91,986, riguarda il ramo 4, con miglior costo 396,500. Il ramo più mal previsto non è quindi quello con il miglior giro. Inoltre il ramo 6 è stimato più economico del suo costo vero: è sfavorito per il confronto relativo con gli altri rami, non perché il modello ne sovrastimi necessariamente il costo. Questo distingue errore assoluto, ordinamento delle alternative e beneficio della ricerca aggiuntiva. I riferimenti esatti sono solo diagnostici offline e non guidano C.

8.7 Prova esplorativa con due modelli

Sulla stessa mappa personale da cento consegne, a un secondo nominale, sostituire il modello allenato su sei consegne con quello allenato su cento riduce il costo di B da 3594,661 a 3150,594 (12,35%). C passa da 3513,976 a 3206,702, ma con il nuovo modello resta peggiore di B dell'1,78%. Sono due modelli specifici su una singola mappa: il risultato non isola l'effetto del numero di consegne di allenamento e non dimostra da solo generalizzazione a distribuzioni diverse.

Domande che mi sono posto

Il confronto A–B misura il contributo della previsione; B–C quello aggiuntivo della regolazione. Per interpretare i risultati ho considerato le seguenti domande.

Perché usare la stagnazione come segnale? È semplice da osservare: dopo molte estrazioni senza miglioramenti, il regolatore prova un candidato diverso. La stagnazione non misura direttamente l'errore del modello e non garantisce che cambiare candidato sia utile. Le misure di lavoro mostrano che le scansioni della pila consumano risorse; il costo parziale minimo può favorire stati poco profondi: sono possibili cause dei peggioramenti, che queste prove non permettono di distinguere.

Perché la massa irrisolta resta circa uno? Una prima scelta rimane irrisolta finché il suo sottoalbero contiene almeno un candidato attivo. Con cento consegne, nei tempi disponibili nessuno di questi grandi sottoalberi viene interamente risolto. La misura distingue quindi poco i metodi: trovare un buon giro non equivale a risolvere tutte le alternative del suo ramo.

Dieci mappe bastano per concludere che la regolazione aiuta? Descrivono il comportamento sui casi studiati: C migliora B su sei mappe a un secondo e su sette a tre secondi, ma perde sulle altre. Ripetere le stesse mappe verifica la stabilità dell'esecuzione, senza aumentare i casi indipendenti. Per generalizzare servirebbero più mappe e distribuzioni diverse da quella dell'allenamento.

Il confronto è equo se il limite di tempo viene superato? I tre metodi ricevono lo stesso budget nominale, ma il controllo avviene fra iterazioni: un'operazione iniziata può terminare oltre la scadenza. Per questo riporto i tempi effettivi e considero le risorse solo approssimativamente uguali. Una scadenza più rigorosa richiederebbe controlli anche durante le operazioni costose del regolatore.

Il sistema è migliore degli altri algoritmi per il TSP? Il vantaggio osservato riguarda la specifica baseline scelta, una DFS con branch-and-bound sul costo già percorso. Non permette di concludere che il sistema superi altre euristiche per il TSP. Infatti, sulle mappe grandi il riferimento euristico trova giri migliori dei tre metodi, senza certificare l'ottimo. L'obiettivo dell'esperimento è studiare il contributo della previsione e della regolazione a questa ricerca.

Registro delle decisioni supportate da AI

1. **Previsione del costo rimanente.** Richiesta: costruire un modello a partire dagli stati della ricerca. Proposta: regressione lineare su quattro feature geometriche. Esito: accettata. Motivo: permette di distinguere chiaramente input, target e costo già percorso, con un modello leggibile.

2. **Regolazione per stagnazione.** Richiesta: modificare la scelta dei candidati quando la ricerca non migliora. Proposta: estrarre uno stato con costo parziale minimo dopo stagnazione. Esito: modificata introducendo una pausa fra gli interventi. Motivo: una diversificazione continua può privilegiare stati poco profondi.

3. **Probabilità e diagnosi.** Richiesta: completare i punti su probabilità, massa irrisolta ed errore. Proposta: softmax sulle prime scelte, monitoraggio dei sottoalberi e confronto con completamenti indipendenti. Esito: mantenuta nel progetto. Motivo: rendere osservabile la differenza fra preferenza iniziale e utilità effettiva dell'esplorazione, senza usare l'ottimo nelle decisioni online.

4. **Dataset per l'esperimento principale.** Richiesta: usare mappe più grandi. Proposta: programma separato con dati in memoria. Esito: rifiutata; adottato un dataset persistente nel programma esistente. Motivo: separare chiaramente allenamento e prova.