Ricerca predittiva regolata

Un esperimento sul giro di consegne

Francesco Vampa, Matricola 316461

30 ottobre 2026

Introduzione

Un corriere deve partire dal deposito, visitare tutte le consegne una sola volta e tornare al deposito, percorrendo meno strada possibile. Rappresentiamo le località con punti su un piano e usiamo le distanze euclidee: si tratta del problema del commesso viaggiatore euclideo, o TSP.

Il progetto studia come scegliere le possibilità da esplorare quando il calcolo disponibile è limitato. Confrontiamo una ricerca di base, una ricerca guidata da un modello appreso e una ricerca che aggiunge un regolatore. Il modello indica quali percorsi sembrano promettenti; il regolatore osserva l'andamento della ricerca e può cambiare dove dedicare il calcolo. La relazione segue gli otto punti dell'assignment.

1 Ricerca

Cerchiamo un ordine di visita delle consegne. Uno stato contiene il percorso parziale p, l'insieme N delle consegne ancora da visitare e il costo g già percorso. Per esempio, $p = (0, 2)$ indica la partenza dal deposito 0 e la visita della consegna 2: le consegne rimanenti devono ancora essere ordinate. Un'espansione genera un successore per ciascuna consegna in N, aggiornando percorso, insieme residuo e costo. Quando N è vuoto si aggiunge il ritorno al deposito e si valuta il giro completo.

La baseline è una visita in profondità, DFS, con una pila: viene estratto l'ultimo stato inserito. Il branch-and-bound conserva il miglior giro trovato e scarta uno stato se il suo costo già percorso è almeno pari al costo di quel giro. La potatura è sicura perché le distanze aggiunte non sono negative. La ricerca termina quando esaurisce le alternative o il budget disponibile. Se termina per budget, il giro restituito può essere buono senza essere un ottimo dimostrato.

L'*orizzonte* è il confine dell'albero costruito: comprende gli stati pendenti, i giri già valutati e i rami potati. La *frontiera attiva* è soltanto la parte ancora candidata a ricevere calcolo: gli stati pendenti con g minore del miglior costo completo. I rami potati non devono essere approfonditi; quelli lasciati pendenti alla scadenza restano irrisolti. Quindi orizzonte e frontiera attiva sono diversi. Alcuni stati possono rimanere materialmente nella pila pur essendo ormai esclusi dal limite: vengono scartati quando sono estratti.

2 Introduzione della previsione

Il modello prevede il *costo rimanente*: la distanza necessaria per completare un percorso parziale e tornare al deposito. Il costo già percorso è noto e non deve essere previsto. Indichiamo la stima con $\widehat{h}(s)$.

Usiamo una regressione lineare con quattro informazioni dello stato: numero di consegne rimaste, distanza dal deposito, distanza dalla consegna rimasta più vicina e distanza media dalle consegne rimaste. Il modello impara quattro pesi e un'intercetta. È semplice da leggere, ma queste informazioni riassuntive non descrivono tutta la geometria della mappa. Perciò la stima può sbagliare e non viene trattata come un limite sicuro.

3 Origine dei target

Per allenare il modello servono stati parziali e valori di riferimento, chiamati *target*. Per ogni stato, un procedimento separato completa il percorso mantenendo fisse le consegne già visitate. Dal costo totale del completamento si sottrae g, ottenendo il costo ancora necessario.

Sulle mappe ridotte usiamo come insegnante un branch-and-bound completo: conserviamo il target soltanto se l'ottimo è certificato. Quando una ricerca completa è impraticabile, usiamo invece completamenti approssimati. Si visita ogni volta una consegna vicina e si migliora il giro con 2-opt: si invertono tratti del percorso se la distanza diminuisce. Proviamo più partenze e conserviamo il completamento migliore. Questo target è il costo di un giro ammissibile, non un ottimo dimostrato.

Campioniamo percorsi parziali con molte e poche consegne residue, alternando prefissi casuali e prefissi costruiti visitando consegne vicine. Separiamo le mappe di allenamento da quelle di prova: stati della stessa mappa non vengono distribuiti fra i due gruppi. La generazione dei target e il fit sono operazioni offline, esterne al budget della ricerca valutata.

4 Ricerca predittiva

Per scegliere quali successori esplorare prima, il sistema B confronta il costo totale stimato:

$$\widehat{f}(s) = g(s) + \widehat{h}(s).$$

Si include g perché una continuazione economica potrebbe appartenere a un percorso già molto costoso. I successori sono inseriti nella pila in ordine decrescente di stima, così il meno costoso viene estratto per primo. L'ordinamento è locale ai successori: la ricerca resta in profondità. Se non restano consegne, si usa il costo esatto di ritorno al deposito.

Questa versione usa sempre lo stesso criterio predittivo e non osserva la stagnazione per cambiare politica. La potatura rimane quella sicura sul costo già percorso. Una previsione sbagliata può quindi ritardare un buon ramo, ma non lo elimina definitivamente. Con ricerca completa l'ottimo resta garantito; con budget limitato l'ordine può influire sul giro trovato.

5 Regolazione della ricerca predittiva

Il sistema C usa lo stesso modello di B e osserva due contatori: q, estrazioni dall'ultimo miglioramento del giro, e c, estrazioni ordinarie dall'ultima diversificazione. Quando entrambi raggiungono la soglia fissata, il regolatore sceglie dalla pila lo stato con costo parziale g minimo, al posto della normale estrazione LIFO. Il candidato scelto riceve la successiva unità di calcolo; gli altri rimangono disponibili. Non vengono introdotte potature basate sul modello.

Un giro migliore azzera q; una diversificazione azzera c. Prima del primo giro, q conta le estrazioni dall'avvio. Il secondo contatore distanzia gli interventi, lasciando spazio alla ricerca predittiva. La corrispondenza richiesta dall'assignment è dunque: osservazioni $O = (q, c)$, regola sulle soglie, decisione di cambiare il prossimo stato.

La stagnazione motiva un tentativo in una direzione diversa, ma non dimostra che la previsione sia sbagliata. Anche un costo parziale basso può condurre a un giro lungo. Inoltre, cercare il minimo nella pila richiede una scansione: il regolatore aggiunge lavoro e può far crescere la frontiera senza migliorare il risultato.

6 Errore di previsione e bisogno di ricerca

Valutiamo l'accuratezza confrontando le stime con i target delle mappe escluse dall'allenamento. Usiamo l'errore assoluto medio, MAE: la media delle differenze in valore assoluto. Come confronto semplice prevediamo sempre la media dei target di allenamento. Un MAE minore misura una previsione più accurata rispetto ai target, non necessariamente un giro migliore.

Per un singolo stato il residuo è $r(s) = h_{\text{rif}}(s) - \widehat{h}(s)$. Un residuo positivo indica che il modello sottostima il costo rimanente; uno negativo indica una sovrastima. Se il riferimento è approssimato, questo è uno scarto dal riferimento, non l'errore esatto rispetto all'ottimo.

Un grande errore può segnalare una stima poco affidabile, ma non basta per stabilire dove cercare: un ramo molto mal previsto può comunque essere peggiore degli altri. Il residuo esatto si conosce solo dopo la ricerca aggiuntiva e non guida il regolatore online. Per il bisogno di ulteriore esplorazione usiamo la stagnazione come segnale operativo, valutandone i benefici tramite i risultati e le tracce dei rami visitati. Il caso concreto della Sezione 8 mostra perché può valere la pena cercare anche in un ramo sfavorito dal modello.

7 Scelta probabilistica e massa irrisolta

Consideriamo le alternative alla prima decisione: quale consegna visitare dopo il percorso iniziale. Ogni scelta identifica un sottoalbero di completamenti. Trasformiamo i costi totali previsti in una distribuzione:

$$\pi(a \mid s_0) = \frac{\exp[-(\widehat{f}_a - m)/T]}{\sum_b \exp[-(\widehat{f}_b - m)/T]}, \qquad m = \min_b \widehat{f}_b.$$

La temperatura T è la distanza media fra coppie di luoghi; vale uno se tutte le distanze sono nulle. Queste probabilità esprimono preferenze di esplorazione: costi stimati minori ricevono peso maggiore. Non sono confidenze calibrate sull'ottimalità. La ricerca resta deterministica: non campiona azioni. Cambiare T modifica i pesi, ma non l'ordine delle stime.

Un'azione resta irrisolta se il suo sottoalbero contiene almeno uno stato della frontiera attiva. La massa irrisolta è la somma delle probabilità di queste azioni, ciascuna contata una volta:

$$\rho = \sum_{a \in U} \pi(a \mid s_0).$$

Trovare un giro in un ramo non risolve tutti gli altri completamenti possibili di quel ramo. La distribuzione iniziale rimane fissa durante la prova; il cambiamento di massa dipende dalla ricerca. La stessa misura è applicata ai tre sistemi, ma la baseline non la usa per scegliere e il regolatore continua a osservare i due contatori. Una massa positiva non è una probabilità di aver mancato l'ottimo e non equivale al numero di stati pendenti.

8 Esperimento

Task e dati. Il task è costruire un giro dal deposito che visiti tutte le consegne e torni al punto di partenza. Il dataset iniziale contiene 12 mappe di allenamento e 3 di verifica, ciascuna con 100 consegne, deposito in $(0, 0)$ e coordinate uniformi in $[0, 100]^2$. I 40 stati parziali per mappa

forniscono 480 esempi di allenamento e 120 di verifica. Su questi ultimi il MAE è 49,391, contro 184,684 della previsione costante. È uno scarto dai target euristici, non dall'ottimo.

Il confronto principale usa **dieci ulteriori mappe**, escluse dal dataset iniziale e generate con la stessa distribuzione. Il modello rimane fisso. L'insegnante usa tre partenze e sei passate di 2-opt; il riferimento finale usa dodici partenze e venti passate. Questi calcoli sono offline e non forniscono soluzioni iniziali o suggerimenti ai tre metodi.

Protocollo. Confrontiamo A, ricerca di base; B, ricerca predittiva; C, ricerca predittiva regolata. Ogni ricerca riparte dal deposito, senza un giro iniziale. La soglia del regolatore rimane 100, fissata prima di queste prove. Per ciascuna mappa assegniamo a ogni metodo un budget nominale di 1 e 3 secondi, con tre ripetizioni per budget. I metodi vengono eseguiti in sequenza e l'ordine ruota: ciascuno occupa una volta ogni posizione. Un esperimento completo contiene quindi 180 ricerche. Preparazione, riferimenti e statistiche finali sono esclusi dal budget; il monitoraggio interno è incluso.

Le tabelle riportano la **distanza totale mediana di tre esecuzioni**, incluso il ritorno al deposito. Un valore minore è migliore; il migliore fra A, B e C sulla stessa mappa è in grassetto. Usiamo i risultati della seconda esecuzione completa, verificandone la stabilità rispetto alla prima.

Confronto a 1 secondo. Il budget breve permette di osservare quanto rapidamente ciascun metodo riesca a trovare un buon giro.

Mappa	A – Base	B – Predittiva	C – Regolata
1	5032,171	**1232,194**	1260,496
2	4550,280	1238,428	**1199,187**
3	4535,162	**1209,358**	1216,796
4	5184,191	1247,886	**1246,064**
5	4880,372	**1271,490**	1272,012
6	5051,347	1203,630	**1177,426**
7	4865,337	1243,174	**1149,282**
8	5232,949	1283,231	**1150,133**
9	5037,756	**1146,193**	1150,825
10	5293,862	1210,492	**1206,202**

B migliora A su tutte le mappe, con una riduzione media della distanza del 75,20%. C migliora ulteriormente B su sei mappe e peggiora sulle altre quattro. Il guadagno medio aggiuntivo è 2,04%: l'aiuto del regolatore non è uniforme, passando da un peggioramento del 2,30% sulla mappa 1 a un miglioramento del 10,37% sulla mappa 8.

Confronto a 3 secondi. Ripetiamo il confronto sulle stesse mappe, con lo stesso modello e la stessa soglia, aumentando soltanto il tempo assegnato. Ogni ricerca riparte da zero.

Mappa	A – Base	B – Predittiva	C – Regolata
1	4946,385	1229,267	**1183,694**
2	4542,940	1237,996	**1199,187**
3	4516,857	1207,742	**1160,431**
4	5142,859	**1242,330**	1245,519
5	4869,099	1271,490	**1257,145**
6	5039,634	1199,439	**1177,426**
7	4834,985	1240,967	**1149,282**
8	5231,129	1283,231	**1150,133**
9	4990,438	**1146,193**	1150,825
10	5281,628	**1204,769**	1206,202

B mantiene un vantaggio medio del 75,11% su A. C supera B in sette mappe su dieci, con un guadagno medio del 3,07%. Sulle mappe 1 e 3, per esempio, C passa da un risultato peggiore a

uno migliore di B. Tuttavia, C resta peggiore sulla mappa 9 e diventa peggiore sulle mappe 4 e 10: più tempo non garantisce un vantaggio relativo della regolazione su ogni caso. Le percentuali sono medie dei guadagni calcolati separatamente per mappa, non riduzioni rispetto a un ottimo noto.

Stabilità e risorse. Abbiamo eseguito due volte l'intero protocollo. Le distanze mediane di B e C coincidono nelle due esecuzioni; per A cambia soltanto una mappa a 3 secondi, di circa lo 0,52%. I casi indipendenti restano dieci: ripetere una mappa non produce un nuovo caso. Il tempo è controllato fra iterazioni e l'ultima operazione può superare il limite. Nei due esperimenti, i massimi osservati per C sono circa 1,12 e 3,26 secondi, rispettivamente. Il confronto è quindi a risorse approssimativamente uguali, non a scadenza temporale rigorosa.

Un caso verificabile di ricerca utile. Riproduciamo anche un caso illustrativo già individuato, con sei consegne e un modello distinto. Il ramo classificato ultimo contiene un giro ottimo. Con 500 estrazioni B non lo visita e trova costo 354,992; C lo apre al passo 387 e trova costo 349,580 al passo 421. L'enumerazione indipendente conferma l'ottimo, raggiunto anche da A entro lo stesso budget.

Il modello stima per quel ramo un costo totale di 340,181: il residuo è 9,400. Il ramo con il residuo maggiore, 91,986, conduce invece al miglior costo di 396,500. Quindi l'errore più grande non identifica da solo il ramo più utile. Questo caso mostra il valore di esplorare anche alternative sfavorite dal modello, ma non è una nuova conferma indipendente né dimostra che la stagnazione individui sempre la scelta migliore.

Prova personale con due modelli. In una prova esplorativa sulla stessa mappa personale da 100 consegne e con un secondo nominale, sostituire il modello allenato su sei consegne con quello allenato su cento riduce il costo di B da 3594,661 a 3150,594 (12,35%). C passa da 3513,976 a 3206,702, ma con il nuovo modello resta peggiore di B dell'1,78%. Il risultato riguarda questi due modelli specifici e una singola mappa, non isola l'effetto della dimensione di allenamento.

Interpretazione e limiti

A–B distingue il contributo della previsione; B–C quello aggiuntivo della regolazione. Su queste dieci mappe la previsione produce il beneficio maggiore, mentre la regolazione migliora mediamente il giro ma può peggiorarlo. Le scansioni della pila consumano tempo e la preferenza per costi parziali bassi può favorire stati poco profondi. Sono possibili spiegazioni dei peggioramenti; le prove non isolano quale meccanismo prevalga.

I riferimenti euristici trovano giri migliori dei tre sistemi sulle mappe grandi, ma non certificano l'ottimo. La massa irrisolta resta circa 1: ciascuna prima scelta conserva candidati attivi, rendendo questa misura poco informativa ai budget considerati. Non significa che i giri siano errati.

Le due esecuzioni mostrano stabilità su dieci mappe della stessa distribuzione dell'allenamento. Non costituiscono una dimostrazione statistica di un vantaggio generale, né garantiscono lo stesso comportamento su distribuzioni diverse.

Riproduzione dell'esperimento

Dalla cartella del progetto Python, con dati e modelli inclusi:

```
python3 -m src.main --mode experiment
```

Il comando esegue le dieci mappe e il caso piccolo senza riallenare i modelli. Salva coordinate, parametri, percorsi, tempi e riepilogo in `results/esperimenti/`. Le tabelle provengono dall'esecuzione `2026-10-30_11-42-32_bf6d442b`. Dataset originali, comandi di allenamento e istruzioni per le mappe personali sono descritti nel README.

A Registro delle decisioni supportate da AI

1. **Previsione del costo rimanente.** Richiesta: costruire un modello a partire dagli stati della ricerca. Proposta: regressione lineare su quattro feature geometriche. Esito: accettata. Motivo: permette di distinguere chiaramente input, target e costo già percorso, con un modello leggibile.

2. **Regolazione per stagnazione.** Richiesta: modificare la scelta dei candidati quando la ricerca non migliora. Proposta: estrarre uno stato con costo parziale minimo dopo stagnazione. Esito: modificata introducendo una pausa fra gli interventi. Motivo: una diversificazione continua può privilegiare stati poco profondi.

3. **Probabilità e diagnosi.** Richiesta: completare i punti su probabilità, massa irrisolta ed errore. Proposta: softmax sulle prime scelte, monitoraggio dei sottoalberi e confronto con completamenti indipendenti. Esito: mantenuta nel progetto. Motivo: rendere osservabile la differenza fra preferenza iniziale e utilità effettiva dell'esplorazione, senza usare l'ottimo nelle decisioni online.

4. **Dataset per l'esperimento principale.** Richiesta: usare mappe più grandi. Proposta: programma separato con dati in memoria. Esito: rifiutata; adottato un dataset persistente nel programma esistente. Motivo: separare chiaramente allenamento e prova.