Ricerca predittiva regolata

Un esperimento sul giro di consegne

Francesco Vampa — Matricola 316461

27 ottobre 2026

Introduzione

Un corriere deve partire dal deposito, visitare tutte le consegne una sola volta e tornare al deposito, percorrendo meno strada possibile. Rappresentiamo le località con punti su un piano e usiamo le distanze euclidee: si tratta del problema del commesso viaggiatore euclideo, o TSP.

Il progetto studia come scegliere le possibilità da esplorare quando il calcolo disponibile è limitato. Confrontiamo una ricerca di base, una ricerca guidata da un modello appreso e una ricerca che aggiunge un regolatore. Il modello indica quali percorsi sembrano promettenti; il regolatore osserva l'andamento della ricerca e può cambiare dove dedicare il calcolo. La relazione segue gli otto punti dell'assignment.

1 Ricerca

Cerchiamo un ordine di visita delle consegne. Uno stato contiene il percorso parziale p, l'insieme N delle consegne ancora da visitare e il costo g già percorso. Per esempio, $p = (0, 2)$ indica la partenza dal deposito 0 e la visita della consegna 2: le consegne rimanenti devono ancora essere ordinate. Un'espansione genera un successore per ciascuna consegna in N, aggiornando percorso, insieme residuo e costo. Quando N è vuoto si aggiunge il ritorno al deposito e si valuta il giro completo.

La baseline è una visita in profondità, DFS, con una pila: viene estratto l'ultimo stato inserito. Il branch-and-bound conserva il miglior giro trovato e scarta uno stato se il suo costo già percorso è almeno pari al costo di quel giro. La potatura è sicura perché le distanze aggiunte non sono negative. La ricerca termina quando esaurisce le alternative o il budget disponibile. Se termina per budget, il giro restituito può essere buono senza essere un ottimo dimostrato.

L'*orizzonte* è il confine dell'albero costruito: comprende gli stati pendenti, i giri già valutati e i rami potati. La *frontiera attiva* è soltanto la parte ancora candidata a ricevere calcolo: gli stati pendenti con g minore del miglior costo completo. I rami potati non devono essere approfonditi; quelli lasciati pendenti alla scadenza restano irrisolti. Quindi orizzonte e frontiera attiva sono diversi. Alcuni stati possono rimanere materialmente nella pila pur essendo ormai esclusi dal limite: vengono scartati quando sono estratti.

2 Introduzione della previsione

Il modello prevede il *costo rimanente*: la distanza necessaria per completare un percorso parziale e tornare al deposito. Il costo già percorso è noto e non deve essere previsto. Indichiamo la stima con $\widehat{h}(s)$.

Usiamo una regressione lineare con quattro informazioni dello stato: numero di consegne rimaste, distanza dal deposito, distanza dalla consegna rimasta più vicina e distanza media dalle consegne rimaste. Il modello impara quattro pesi e un'intercetta. È semplice da leggere, ma queste informazioni riassuntive non descrivono tutta la geometria della mappa. Perciò la stima può sbagliare e non viene trattata come un limite sicuro.

3 Origine dei target

Per allenare il modello servono stati parziali e valori di riferimento, chiamati *target*. Per ogni stato, un procedimento separato completa il percorso mantenendo fisse le consegne già visitate. Dal costo totale del completamento si sottrae g, ottenendo il costo ancora necessario.

Sulle mappe ridotte usiamo come insegnante un branch-and-bound completo: conserviamo il target soltanto se l'ottimo è certificato. Quando una ricerca completa è impraticabile, usiamo invece completamenti approssimati. Si visita ogni volta una consegna vicina e si migliora il giro con 2-opt: si invertono tratti del percorso se la distanza diminuisce. Proviamo più partenze e conserviamo il completamento migliore. Questo target è il costo di un giro ammissibile, non un ottimo dimostrato.

Campioniamo percorsi parziali con molte e poche consegne residue, alternando prefissi casuali e prefissi costruiti visitando consegne vicine. Separiamo le mappe di allenamento da quelle di prova: stati della stessa mappa non vengono distribuiti fra i due gruppi. La generazione dei target e il fit sono operazioni offline, esterne al budget della ricerca valutata.

4 Ricerca predittiva

Per scegliere quali successori esplorare prima, il sistema B confronta il costo totale stimato:

$$\widehat{f}(s) = g(s) + \widehat{h}(s).$$

Si include g perché una continuazione economica potrebbe appartenere a un percorso già molto costoso. I successori sono inseriti nella pila in ordine decrescente di stima, così il meno costoso viene estratto per primo. L'ordinamento è locale ai successori: la ricerca resta in profondità. Se non restano consegne, si usa il costo esatto di ritorno al deposito.

Questa versione usa sempre lo stesso criterio predittivo e non osserva la stagnazione per cambiare politica. La potatura rimane quella sicura sul costo già percorso. Una previsione sbagliata può quindi ritardare un buon ramo, ma non lo elimina definitivamente. Con ricerca completa l'ottimo resta garantito; con budget limitato l'ordine può influire sul giro trovato.

5 Regolazione della ricerca predittiva

Il sistema C usa lo stesso modello di B e osserva due contatori: q, estrazioni dall'ultimo miglioramento del giro, e c, estrazioni ordinarie dall'ultima diversificazione. Quando entrambi raggiungono la soglia fissata, il regolatore sceglie dalla pila lo stato con costo parziale g minimo, al posto della normale estrazione LIFO. Il candidato scelto riceve la successiva unità di calcolo; gli altri rimangono disponibili. Non vengono introdotte potature basate sul modello.

Un giro migliore azzera q; una diversificazione azzera c. Prima del primo giro, q conta le estrazioni dall'avvio. Il secondo contatore distanzia gli interventi, lasciando spazio alla ricerca predittiva. La corrispondenza richiesta dall'assignment è dunque: osservazioni $O = (q, c)$, regola sulle soglie, decisione di cambiare il prossimo stato.

La stagnazione motiva un tentativo in una direzione diversa, ma non dimostra che la previsione sia sbagliata. Anche un costo parziale basso può condurre a un giro lungo. Inoltre, cercare il minimo nella pila richiede una scansione: il regolatore aggiunge lavoro e può far crescere la frontiera senza migliorare il risultato.

6 Errore di previsione e bisogno di ricerca

Valutiamo l'accuratezza confrontando le stime con i target delle mappe escluse dall'allenamento. Usiamo l'errore assoluto medio, MAE: la media delle differenze in valore assoluto. Come confronto semplice prevediamo sempre la media dei target di allenamento. Un MAE minore misura una previsione più accurata rispetto ai target, non necessariamente un giro migliore.

Per un singolo stato il residuo è $r(s) = h_{\text{rif}}(s) - \widehat{h}(s)$. Un residuo positivo indica che il modello sottostima il costo rimanente; uno negativo indica una sovrastima. Se il riferimento è approssimato, questo è uno scarto dal riferimento, non l'errore esatto rispetto all'ottimo.

Un grande errore può segnalare una stima poco affidabile, ma non basta per stabilire dove cercare: un ramo molto mal previsto può comunque essere peggiore degli altri. Il residuo esatto si conosce solo dopo la ricerca aggiuntiva e non guida il regolatore online. Per il bisogno di ulteriore esplorazione usiamo la stagnazione come segnale operativo, valutandone i benefici tramite i risultati e le tracce dei rami visitati. Il caso concreto della Sezione 8 mostra perché può valere la pena cercare anche in un ramo sfavorito dal modello.

7 Scelta probabilistica e massa irrisolta

Consideriamo le alternative alla prima decisione: quale consegna visitare dopo il percorso iniziale. Ogni scelta identifica un sottoalbero di completamenti. Trasformiamo i costi totali previsti in una distribuzione:

$$\pi(a \mid s_0) = \frac{\exp[-(\widehat{f}_a - m)/T]}{\sum_b \exp[-(\widehat{f}_b - m)/T]}, \qquad m = \min_b \widehat{f}_b.$$

La temperatura T è la distanza media fra coppie di luoghi; vale uno se tutte le distanze sono nulle. Queste probabilità esprimono preferenze di esplorazione: costi stimati minori ricevono peso maggiore. Non sono confidenze calibrate sull'ottimalità. La ricerca resta deterministica: non campiona azioni. Cambiare T modifica i pesi, ma non l'ordine delle stime.

Un'azione resta irrisolta se il suo sottoalbero contiene almeno uno stato della frontiera attiva. La massa irrisolta è la somma delle probabilità di queste azioni, ciascuna contata una volta:

$$\rho = \sum_{a \in U} \pi(a \mid s_0).$$

Trovare un giro in un ramo non risolve tutti gli altri completamenti possibili di quel ramo. La distribuzione iniziale rimane fissa durante la prova; il cambiamento di massa dipende dalla ricerca. La stessa misura è applicata ai tre sistemi, ma la baseline non la usa per scegliere e il regolatore continua a osservare i due contatori. Una massa positiva non è una probabilità di aver mancato l'ottimo e non equivale al numero di stati pendenti.

8 Esperimento

Task e dati. Ogni task è una mappa: il sistema deve costruire un giro che parta dal deposito, visiti tutte le consegne e torni al deposito. L'esperimento principale usa mappe con 100 consegne e deposito in $(0, 0)$, con coordinate generate uniformemente in $[0, 100]^2$. Il dataset salvato contiene

12 mappe per allenare e 3 mappe nuove per provare il sistema. Campioniamo 40 stati per mappa: 480 esempi di allenamento e 120 di prova. Nel confronto principale il modello viene allenato una volta e rimane fisso durante i task di prova.

Protocollo. Su ciascuna delle tre mappe confrontiamo A, baseline; B, predittiva; C, predittiva regolata. Tutti partono dal deposito, senza soluzioni iniziali, e ogni esecuzione riparte da zero. La soglia del regolatore è 100, fissata nelle prove preliminari. L'insegnante usa tre partenze e sei passate di 2-opt; il riferimento finale usa dodici partenze e venti passate. Questi riferimenti sono calcolati offline e non vengono passati alle ricerche online come soluzioni iniziali o suggerimenti.

Facciamo due confronti: 5 000 estrazioni per metodo e un secondo di ricerca per metodo. Il primo pareggia gli stati esaminati; il secondo il tempo assegnato al ciclo di ricerca. Preparazione dei dati, riferimenti e raccolta finale delle statistiche sono esterni al limite temporale. Il tempo è controllato fra iterazioni e può essere superato dall'ultima iterazione. I risultati temporizzati possono cambiare fra esecuzioni.

Tabella 1: Distanza totale dei giri trovati: un valore minore è migliore. La seconda prova assegna un secondo di ricerca a ogni metodo.

Budget	Mappa	A	B	C
5 000 stati	1	5236,435	1434,007	1311,845
5 000 stati	2	5453,993	1346,243	1270,629
5 000 stati	3	5029,908	1395,538	1373,503
1 secondo	1	5134,219	1434,007	1311,845
1 secondo	2	5295,162	1308,793	1306,856
1 secondo	3	4864,579	1386,645	1380,646

Il MAE rispetto ai target di prova è 49,391 per il modello e 184,684 per la previsione costante. Si misura la coerenza con i completamenti euristici, non l'errore esatto dall'ottimo. Il riferimento finale trova distanze rispettivamente pari a 866,325, 832,224 e 867,337: non sono ottimi certificati e non calcoliamo un gap dall'ottimo su queste mappe.

Con il budget di stati i tempi medi osservati, compreso il resoconto finale, sono circa 0,015, 0,054 e 1,455 secondi per A, B e C. La distanza migliore di C non implica quindi maggiore velocità. Nel confronto temporizzato C trova ancora giri migliori di B nei tre casi osservati, con differenze ridotte nelle ultime due mappe. La frontiera di C cresce molto e la scansione richiesta dalle diversificazioni è costosa. La massa irrisolta resta circa 1 per tutti: a questi budget ogni prima scelta conserva almeno un candidato attivo. È un limite informativo della misura, non una certificazione che i giri siano sbagliati.

Cambio del modello su una mappa personale. Su un'ulteriore mappa da 100 consegne inserita a mano, esclusa dall'allenamento, confrontiamo i due modelli disponibili. Manteniamo le stesse coordinate, soglia 100 e limite nominale di un secondo per ogni ricerca.

Tabella 2: Stessa mappa personale, due modelli. B è la ricerca predittiva; C aggiunge il regolatore.

Allenamento del modello	Costo B	Costo C
6 consegne	3594,661	3513,976
100 consegne	3150,594	3206,702

La sostituzione del modello riduce il costo trovato da B del 12,35%. Con il nuovo modello, però, C trova un giro più lungo di B dell'1,78%: la regolazione qui peggiora il risultato finale. Le diversificazioni possono interrompere un'esplorazione utile o consumare tempo, ma questa prova non identifica quale causa prevalga. Il confronto riguarda questi due modelli specifici; una singola esecuzione non dimostra un vantaggio generale.

Un caso verificabile di ricerca utile. In una prova separata con sei consegne e un modello distinto, il ramo classificato ultimo contiene un giro ottimo. Con 500 estrazioni B non lo visita e trova costo 354,992; C lo apre al passo 387 e trova costo 349,580 al passo 421. L'enumerazione indipendente conferma l'ottimo. È un caso concreto di ricerca utile oltre la preferenza iniziale, senza dimostrare che la stagnazione individui sempre il ramo giusto.

Interpretazione e limiti

Il confronto A–B misura il contributo della previsione; B–C quello aggiuntivo della regolazione. Il modello migliora l'ordine di ricerca, mentre il regolatore può aiutare oppure peggiorare, come nella prova personale con il nuovo modello. Scansioni della pila e preferenza per stati poco profondi limitano la scalabilità.

Il riferimento euristico trova giri migliori dei tre sistemi. Il confronto principale usa soltanto tre mappe, più un caso personale; le esecuzioni temporizzate sono singole e dipendono dalla macchina. I risultati osservati non costituiscono una valutazione statistica né dimostrano un vantaggio generale.

Riproduzione dell'esperimento

Dalla cartella del progetto Python, installate le dipendenze di `requirements.txt`, si riproducono le due prove con:

```
python3 -m src.main --deliveries 100 --mode all
python3 -m src.main --deliveries 100 --seconds 1
```

La modalità `all` genera il dataset e allena il modello. Per le mappe personali si usa l'opzione `-input`. Lo storico conserva coordinate, parametri e risultati in `results/storico/`. I comandi dettagliati e i percorsi dei dati sono nel README. Per il controllo ridotto basta la modalità predefinita.

A Registro delle decisioni supportate da AI

1. **Previsione del costo rimanente.** Richiesta: costruire un modello a partire dagli stati della ricerca. Proposta: regressione lineare su quattro feature geometriche. Esito: accettata. Motivo: permette di distinguere chiaramente input, target e costo già percorso, con un modello leggibile.

2. **Regolazione per stagnazione.** Richiesta: modificare la scelta dei candidati quando la ricerca non migliora. Proposta: estrarre uno stato con costo parziale minimo dopo stagnazione. Esito: modificata introducendo una pausa fra gli interventi. Motivo: una diversificazione continua può privilegiare stati poco profondi.

3. **Probabilità e diagnosi.** Richiesta: completare i punti su probabilità, massa irrisolta ed errore. Proposta: softmax sulle prime scelte, monitoraggio dei sottoalberi e confronto con completamenti indipendenti. Esito: mantenuta nel progetto. Motivo: rendere osservabile la differenza fra preferenza iniziale e utilità effettiva dell'esplorazione, senza usare l'ottimo nelle decisioni online.

4. **Dataset per l'esperimento principale.** Richiesta: usare mappe più grandi. Proposta: programma separato con dati in memoria. Esito: rifiutata; adottato un dataset persistente nel programma esistente. Motivo: separare chiaramente allenamento e prova.